STRUMENTI DI BIOSTATISTICA

quattro seminari introduttivi

Massimo Borelli

Corso di Laurea Magistrale in
BIOtecnologie Innovative per la SAlute
UMG

Copyright © 2026 Massimo Borelli, Ph.D.

FREELY AVAILABLE ON HTTPS://GITHUB.COM/UMGSTAT/BIOTEC

Licensed under the Creative Commons Attribution-NonCommercial 4.0 License (the "License"). You may not use this file except in compliance with the License. You may obtain a copy of the License at https://creativecommons.org/licenses/by-nc-sa/4.0. Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

First printing, May 2026

in memoria
i professori Heather Bond e Gianni Morrone

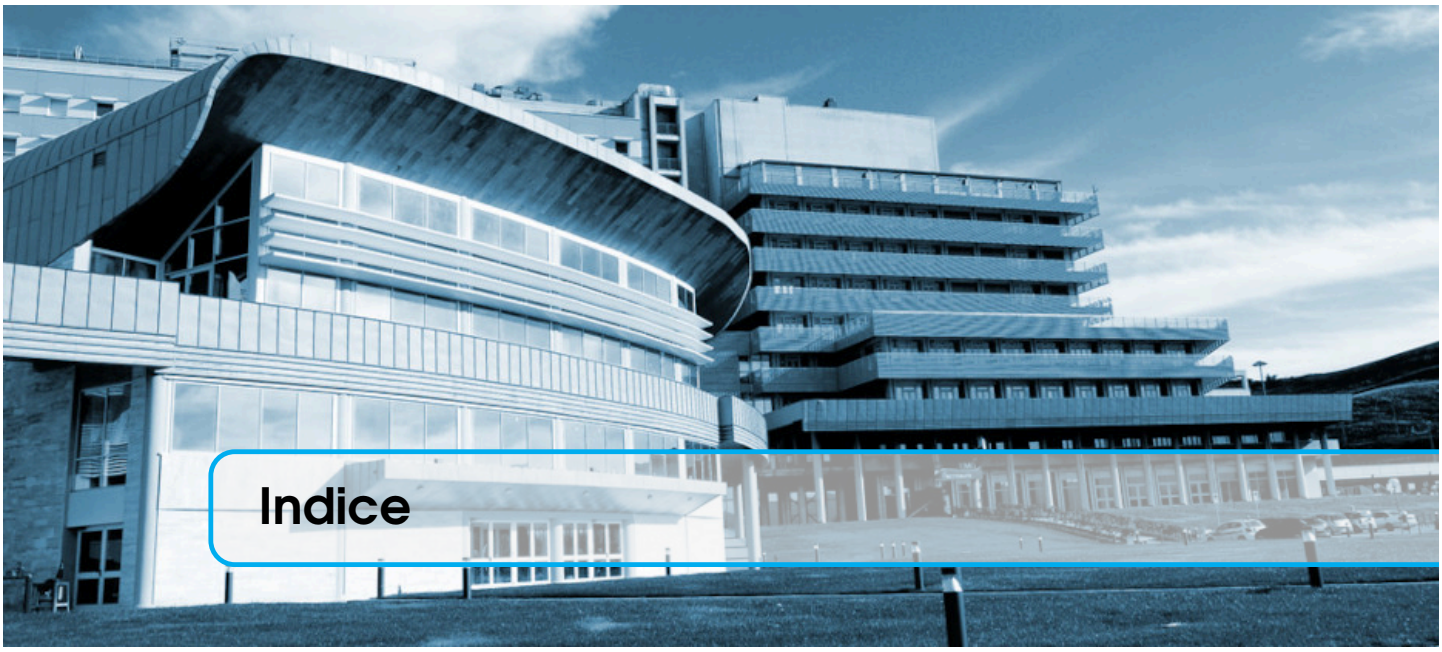

Indice

1 Per iniziare . . . 7

1.1 Biostatistica: una liturgia cosmetica? . . . 7

1.2 Cosa faremo a lezione . . . 8

1.3 ... e se, un domani, volessimo approfondire? . . . 9

1.3.1 Il linguaggio R . . . 9

1.3.2 Le interfacce grafiche utente del linguaggio R . . . 10

1.3.3 JASP . . . 11

1.4 Convenzioni tipografiche di questa dispensa . . . 11

I Il foglio elettronico intelligente

2 Gli strumenti che useremo . . . 15

2.1 Potenzialità e limiti di Google Fogli . . . 15

2.2 Conosciamo l'editor di Apps Script . . . 16

3 Presentare i dati correttamente . . . 19

3.1 Descrizioni numeriche . . . 19

3.1.1 Scheda 1: dati qualitativi e dati quantitativi . . . 19

3.1.2 Attenzione: garantire la qualità del dato . . . 21

3.1.3 Scheda 2: indici di centralità e di dispersione per i dati qualitativi . . . 22

3.1.4 Scheda 3: indici di centralità e di dispersione per i dati quantitativi . . . 25

3.2 Descrizioni grafiche . . . 26

3.2.1 Scheda 4: Rappresentare graficamente i dati . . . 26

3.2.2 Ricordiamoci sempre di rispettare i nostri interlocuori . . . 27

II Tenere sotto controllo il caso

4 Il calcolo della probabilità ci aiuta 31
4.1 La variabile aleatoria binomiale 31
4.1.1 Scheda 10: la distribuzione binomiale 31
4.2 Due pensieri a confronto: von Mises e de Finetti 32
4.3 La distribuzione gaussiana 39
4.3.1 Scheda 11A: la distribuzione gaussiana 39
4.4 La distribuzione lognormale 43
4.4.1 Scheda 11C: la distribuzione log-normale 43
4.5 La distribuzione di Poisson 44
4.5.1 Scheda 11B: la distribuzione di Poisson 45
4.6 Siamo pronti: la famigerata Tabella 1 46
4.7 Quantificare il rischio con il teorema di Bayes 51
4.7.1 Scheda 20: esploriamo l'idea bayesiana 53
4.7.2 Scheda 21: quantificare il rischio 55
4.8 Verifica delle competenze: vale 1 CFU 57

III Dal particolare all'universale

5 Dialogando con Ilenia Aversa 61
5.1 Dal campione alla popolazione 62
5.2 Guai a confondere la variabilità con l'affidabilità 65
5.3 il signor Student ed il suo T-Test 69
5.3.1 Classical One-sample t test 70
5.4 La signora che gustava il the, ed i guai che seguirono 72
5.5 Verifica delle competenze: vale 1 CFU 78

IV Progettare ciò che vogliamo scoprire

6 Dialogando con Flavia Biamonte e Martina Battaglia 81
6.1 Progettare correttamente un esperimento 81
6.2 La questione delle misure ripetute 87

7 Conclusioni e ringraziamenti 99

Bibliography 105
Articles 105
Books 106

Index 107

1. Per iniziare

1.1 Biostatistica: una liturgia cosmetica?

Questo libro raccoglie gli appunti e le schede delle lezioni di un breve corso di Biostatistica tenuto durante il secondo semestre del 2026 presso la Scuola di Farmacia e Nutraceutica dell'Università Magna Græcia di Catanzaro. Questo libro si può scaricare gratuitamente dall'indirizzo https://github.com/umgstat/biotec.

Il ciclo di seminari nasce, nella mente della professoressa Donatella Malanga, un anno fa, nel giardino di casa mia a Trieste, con l'obiettivo di rivolgerci splicitamente alle studentesse ed agli studenti del quinto anno del corso di laurea magistrale in Biotecnologie, per introdurre i concetti fondamentali della biostatistica attraverso un approccio esplicitamente orientato al *ragionamento sui dati*, più che all'uso di specifici software statistici. Infatti, nelle scienze della vita, la statistica rappresenta uno strumento indispensabile per descrivere, interpretare e discutere dati sperimentali; tuttavia, la sua comprensione è spesso ostacolata da 'barriere tecnologiche' (i software specifici per l'analisi dei dati), oppure da formalismi e concetti matematici percepiti come eccessivi, se non arcani; oppure, dall'uso di tecniche che, pur consolidate e potenti, tendono a nascondere i meccanismi concettuali sottostanti alle analisi. Il risultato é che le studentesse e gli studenti vengono indotti a pensare che la biostatistica altro non sia che una **liturgia**: un rituale, una cerimonia di formule e di frasi da scrivere per uno finalitá esclusivamente **cosmetica**: 'abbellire' la tesi, 'impreziosire' la ricerca, far apparire 'professionale' il report.

Abbiamo perciò pensato esplicitamente ai laureandi magistrali in quanto persone che possiedono già una solida formazione disciplinare nelle scienze della vita, ma che non necessariamente sono orientate verso un futuro percorso di ricerca biomedica. Tuttavia, alla maggior parte di essi, nella loro carriera lavorativa futura verrà richiesto di

- avere familiarità con dati sperimentali e numerici;
- raffrontarsi più o meno frequentemente con i risultati statistici riportati nella letteratura scientifica , pur partendo da ricordi e onoscenze statistiche frammentarie;
- sopperire ad una, nella maggior parte dei casi, limitata esperienza di programmazione

Non da ultimo, a breve essi saranno chiamati a redigere la loro tesi magistrale e pertanto, urge qui fornire alcuni strumenti concettuali di base per comprendere, valutare e presentare dati quantitativi in modo consapevole: in breve, stiamo parlando di quella che viene definita come *alfabetizzazione statistica* (*statistical literacy*), intesa come la capacità di:

- comprendere come i dati vengono descritti e sintetizzati;
- formulare correttamente una domanda statistica a partire da un problema scientifico;
- riconoscere le assunzioni dei principali test statistici univariati;

- interpretare correttamente misure di variabilità, intervalli di fiducia ('confidenza') e p–value;
- valutare criticamente analisi statistiche prodotte da altri.

Ecco perchè cercheremo di porre l'enfasi sul *significato* dei risultati statistici (e sui loro limiti), piuttosto che sull'esecuzione meccanica delle analisi per tramite di un software: non ci interessa sapere 'quale pulsante schiacciare', ma piuttosto capire cosa ci sia 'dietro' a quel pulsante, quale sia l'idea di fondo. Sono passati vent'anni ormai da quando, su JAMA [22], si lanciava l'allarme sul fatto che i medici specializzandi statunitensi rischiassero di concludere il loro percorso formativo e divenire specialisti senza avere acquisito gli strumenti statistici necessari per interpretare i risultati pubblicati nelle ricerche cliniche (ed, ironicamente, tale conclusione veniva suffragata da pagine e pagina di confidence interval, p – value, odds ratio e curve di Kaplan Meier: forse per incutere timore agli specializzandi, appunto).

ORIGINAL CONTRIBUTION

RESIDENTS' UNDERSTANDING OF PUBLISHED BIOSTATISTICS AND RESULTS

Medicine Residents' Understanding of the Biostatistics and Results in the Medical Literature

Donna M. Windish, MD, MPH
Stephen J. Huot, MD, PhD
Michael L. Green, MD, MSc

Context Physicians depend on the medical literature to keep current with clinical information. Little is known about residents' ability to understand statistical methods or how to appropriately interpret research outcomes.

Objective To evaluate residents' understanding of biostatistics and interpretation of research results.

Design, Setting, and Participants Multiprogram cross-sectional survey of internal medicine residents.

Main Outcome Measure Percentage of questions correct on a biostatistics/study design multiple-choice knowledge test.

Results The survey was completed by 277 of 367 residents (75.5%) in 11 residency programs. The overall mean percentage correct on statistical knowledge and interpretation of results was 41.4% (95% confidence interval [CI], 39.7%–43.3%) vs 71.5% (95% CI, 57.5%–85.5%) for fellows and general medicine faculty with research training ($P<.001$). Higher scores in residents were associated with additional advanced degrees (50.0% [95% CI, 44.5%–55.5%] vs 40.1% [95% CI, 38.3%–42.0%], $P<.001$); prior biostatistics training (49.2% [95% CI, 42.7%–47.8%] vs 37.9% [95% CI, 35.4%–40.3%], $P=.001$); enrollment in a university-based training program (43.0% [95% CI, 41.0%–45.1%] vs 36.3% [95% CI, 32.6%–40.0%], $P=.002$); and male sex (44.0% [95% CI, 41.4%–46.7%] vs 38.8% [95% CI, 36.4%–41.1%], $P=.004$). On individual knowledge questions, 81.6% correctly interpreted a relative risk. Residents were less likely to know how to interpret an adjusted odds ratio from a multivariate regression analysis (37.4%) or the results of a Kaplan-Meier analysis (10.5%). Seventy-five percent indicated they did not understand all of the statistics they encountered in journal articles, but 95% felt it was important to understand these concepts to be an intelligent reader of the literature.

Conclusions Most residents in this study lacked the knowledge in biostatistics needed to interpret many of the results in published clinical research. Residency programs should include more effective biostatistics training in their curricula to successfully prepare residents for this important lifelong learning skill.

JAMA. 2007;298(9):1010-1022 www.jama.com

Physicians must keep current with clinical information to practice evidence-based medicine (EBM). In doing so, most prefer to seek evidence-based summaries, which give the clinical bottom line,[1] or evidence-based practice guidelines.[1-3] Resources that maintain these information summaries, however, currently include a limited number of common conditions.[4] Thus, to answer many of their clinical questions, physicians need to access reports of original research. This requires the reader to critically appraise the design, conduct, and analysis of each study and subsequently interpret the results.

Several surveys in the 1980s demonstrated that practicing physicians, particularly those with no formal education in epidemiology and biostatistics, had a poor understanding of common statistical tests and limited ability to interpret study results.[5-7] Many physicians likely have increased difficulty today because more complicated statistical methods are being reported in the medical literature.[8] They may be able to understand the analysis and interpretation of results in only 21% of research articles.[9]

Educators have responded by increasing training in critical appraisal and biostatistics throughout the continuum of medical education. Many medical schools currently provide some formal teaching of basic statistical concepts.[9] As part of the Accreditation Council for Graduate Medical Education's practice-based learning and improvement competency, residents must demonstrate ability in "locating, appraising, and assimilating evidence from scientific studies related to their patients' problems and apply knowledge of study designs and statistical methods to the appraisal of

Author Affiliations: Department of Internal Medicine, Yale University School of Medicine, New Haven, Connecticut.
Corresponding Author: Donna M. Windish, MD, MPH, Yale Primary Care Residency Program, 64 Robbins St, Waterbury, CT 06708 (donna.windish@yale.edu).

©2007 American Medical Associations. All rights reserved.

Table 4. Knowledge Scores by Resident Characteristics[a]

Characteristic	Bivariate Analyses: Mean Correct, % (95% CI)	P Value	Multiple Linear Regression: Score Difference, %[b] (95% CI)	P Value
Sex				
Women	39.6 (36.4 to 41.1)	.004[c]	1 [Reference]	.01
Men	44.0 (41.4 to 46.7)		4.4 (0.87 to 7.9)	
Age range, y				
21-25	44.4 (36.8 to 50.0)	.46[d]		
26-30	41.7 (38.5 to 44.0)			
31-35	41.0 (37.0 to 45.0)			
≥36	37.3 (30.4 to 44.2)			
Other advanced degrees				
No	40.1 (38.3 to 42.0)	<.001[c]	1 [Reference]	<.001
Yes	50.0 (41.5 to 58.5)		8.2 (4.2 to 14.3)	
Years since medical school graduation				
≤1	45.2 (42.4 to 48.0)	<.001[e]	1 [Reference]	
1-3	42.2 (38.8 to 45.6)		−2.0 (−5.5 to 2.0)	.29
4-10	36.8 (33.0 to 40.0)		−4.7 (−9.4 to 0.01)	.05
≥11	34.5 (27.9 to 41.1)		−12.3 (−20.2 to −3.3)	.007
Training outside of the United States				
No	45.2 (42.7 to 47.9)	<.001[c]		
Yes	37.9 (35.4 to 40.3)			
Academic affiliation of program				
Community based	36.3 (32.8 to 40.0)	.002[c]	1 [Reference]	.02
University based	43.0 (41.0 to 45.1)		6.6 (0.80 to 10.2)	
Current level of training				
Entering intern	45.6 (42.3 to 48.4)	.01[d]		
Experienced intern[g]	39.2 (35.7 to 42.7)			
Second-year resident	39.3 (34.9 to 43.7)			
Third-year resident	38.4 (33.8 to 43.2)			
Fourth-year resident	43.3 (38.3 to 48.0)			
Chief resident	38.1 (31.3 to 45.2)			
Current residency training program type				
Traditional/categorical medicine	39.8 (37.5 to 42.1)	.003[d]		
Primary care medicine	42.4 (39.0 to 45.8)			
Medicine/pediatrics	54.6 (47.3 to 61.9)			
Medicine/preventive medicine	53.6 (37.8 to 68.0)[f]			
Preliminary/transitional year	41.0 (36.8 to 46.1)			
Previous training/coursework in biostatistics				
No	37.9 (35.4 to 40.3)	.001[c]	1 [Reference]	.04
Yes	45.2 (42.7 to 47.9)		4.5 (0.80 to 9.2)	
Location of biostatistics training				
College	38.1 (31.7 to 44.9)	.004[d]		
Medical school	42.2 (40.0 to 44.5)			
Residency	39.8 (36.2 to 79.4)			
Other	51.0 (44.8 to 57.2)			
Previous training/coursework in epidemiology				
No	37.5 (34.6 to 40.4)	.003[c]		
Yes	43.3 (41.1 to 45.6)			
Previous training/coursework in evidence-based medicine[h]				
No	39.0 (35.8 to 42.1)	.04[c]		
Yes	42.8 (40.7 to 45.0)			
Regularly reads medical journals				
No	42.3 (38.3 to 45.2)	.53[c]		
Yes	41.0 (38.8 to 45.1)			

[a] To adjust for multiple pairwise comparisons, $P<.01$ is considered statistically significant.
[b] Using forward stepwise regression. Covariates date, advanced degree status, years since medical school graduation, program affiliation, and biostatistics training were found to be associated with knowledge scores. The R^2 value for the final model was 0.15.
[c] Analysis by t test.
[d] Analysis by 1-way analysis of variance.
[e] Trend in 1-month 3 to 12 of the intern year.
[f] The medicine/preventive medicine scores were not normally distributed. Median (interquartile range), 45% (35%–75%).
[g] Evidence-based medicine is defined as the integration of the best research evidence with patients' values and clinical circumstances in clinical decision making. This is in contrast to biostatistics, which is the scientific use of quantitative information to describe or draw inferences about natural phenomena, and epidemiology, which is the study of patterns, causes, and control of disease in groups of people.

©2007 American Medical Associations. All rights reserved.

(Reprinted) JAMA, September 5, 2007—Vol 298, No. 9 1015

1.2 Cosa faremo a lezione

Proprio per queste motivazioni, abbiamo scelto di orientare il nostro discorso alle biotecnologie e deliberatamente di 'abbassare la soglia tecnologica iniziale': invece di ricorrere a software statistici (SPSS, SAS, Stata, ...) o linguaggi di programmazione (Python, R, ...) dedicati, il nostro percorso didattico si basa su:

- il foglio elettronico (Google Sheets);
- semplici meccanismi di automazione (Apps Script);
- il supporto dell'intelligenza artificiale per la scrittura e la comprensione del codice (JavaScript).

il foglio elettronico

Vogliamo però mettere le mani avanti: questa scelta non implica affatto che il foglio elettronico sia considerato uno strumento ideale per la statistica avanzata (... anzi ...); essa risponde all'esigenza di una **didattica laboratoriale**, quella cioè di fare esperienza con i dati numerici in un ambiente familiare, che renda i dati e le trasformazioni su di essi trasparenti e direttamente osservabili, mantenendo invariato il livello concettuale richiesto a livello di laurea magistrale italiana. Pertanto, Google Sheets verrà utilizzato come ambiente di lavoro principale perchè consente di:

- essere collaborativi e condividere istantaneamente le esercitazioni
- ridurre l'attrito tecnologico iniziale;
- concentrarsi sui dati e sui concetti statistici;
- rendere visibili le operazioni di manipolazione e le analisi.

l'automazione tramite Apps Script

Le macro verranno introdotte, in forma guidata, con lo scopo di:

- automatizzare procedure ripetitive;
- mostrare il carattere algoritmico di un'analisi statistica;
- introdurre gradualmente ai meno esperti il concetto di codice come descrizione formale di una procedura.

l'intelligenza artificiale

L'intelligenza artificiale verrà utilizzata come strumento di supporto alla scrittura e alla comprensione del codice, non come sostituto del ragionamento statistico. Le decisioni metodologiche, le ipotesi e l'interpretazione dei risultati resteranno sempre in carico agli studenti (ed ai loro mentori).

1.3 ... e se, un domani, volessimo approfondire?

Se un domani vorrete diventare ricercatrici e ricercatori esperti e dovrete eseguire calcoli bioinformatici e biostatistici 'pesanti', diventerà necessario utilizzare un linguaggio di programmazione come Python o Java https://bit.ly/41G0AaQ. Ma se invece dovrete svolgere analisi 'di routine', qualsiasi pacchetto statistico commerciale come SPSS, Stata o SAS https://bit.ly/3tuJTlX rappresenterà una soluzione ottimale. Tuttavia, la comunità accademica è particolarmente affezionata a R, e alle sue versioni più semplici come le cosiddette 'suite statistiche' quali R Commander, Jamovi o JASP. Spendiamo ora poche parole per introdurre quest'ultime.

1.3.1 Il linguaggio R

R è un ambiente software open source per il calcolo statistico e la grafica, che può essere scaricato gratuitamente dai cosiddetti mirror CRAN (Comprehensive R Archive Network) distribuiti in tutto il mondo: https://cran.r-project.org/mirrors.html. R funziona su piattaforme UNIX/Linux, Windows e MacOS. È inoltre possibile sfruttare le risorse di cloud computing e compilare online i propri script su https://rdrr.io/snippets/.

web

Se siete interessate/i ad alcuni dettagli storici, Nick Thieme ha pubblicato un articolo[18] che ripercorre lo straordinario successo di R, nato più o meno venticinque anni fa all'Università di Auckland dalle idee di due professori di statistica: Ross Ihaka e Robert Gentleman. Ulteriori dettagli sono forniti da Carlos Alberto Gòmez Grajales nel suo articolo *Created by statisticians for statisticians: How R took the world of statistics by storm*, apparso su http://www.statisticsviews.com/view/index.html.

Naturalmente, R è molto ben documentato; ad esempio, si possono trovare online libri introduttivi gratuiti, come il testo di Hadley Wickham e Garrett Grolemund [36] *R for data science*, disponibile all'indirizzo https://r4ds.had.co.nz/, oppure il testo di Kim Seefeld ed Ernst Linder *Statistics Using R with Biological Examples*, disponibile su https://cran.r-project.org/doc/contrib/Seefeld_StatsRBio.pdf. Esistono inoltre numerose pagine web, blog e MOOC dedicati a R; ad esempio:

- http://ncss-tech.github.io/stats_for_soil_survey/chapters/
- http://www.sthda.com/english/wiki/r-software
- Quick-R, https://www.statmethods.net/

Sono disponibili anche molti video tutorial su YouTube, cercando https://www.youtube.com/results?search_query=R+tutorial.

Invece di lavorare direttamente nella console di R, molti studiosi preferiscono utilizzare l'Integrated Development Environment (IDE) R Studio https://www.rstudio.com/. R Studio è apprezzato

perché garantisce un ambiente di programmazione e di grafica stabile e ben integrato. Un grave svantaggio di R è sempre stata la sua 'ripida curva di apprendimento': il principiante doveva dedicare molto tempo a fare pratica nella gestione di sintassi e comandi, oltre allo sforzo richiesto per apprendere la Statistica. In questi tempi di intelligenza artificiale gratuita le cose sono diventate molto, ma mooolto più semplici.

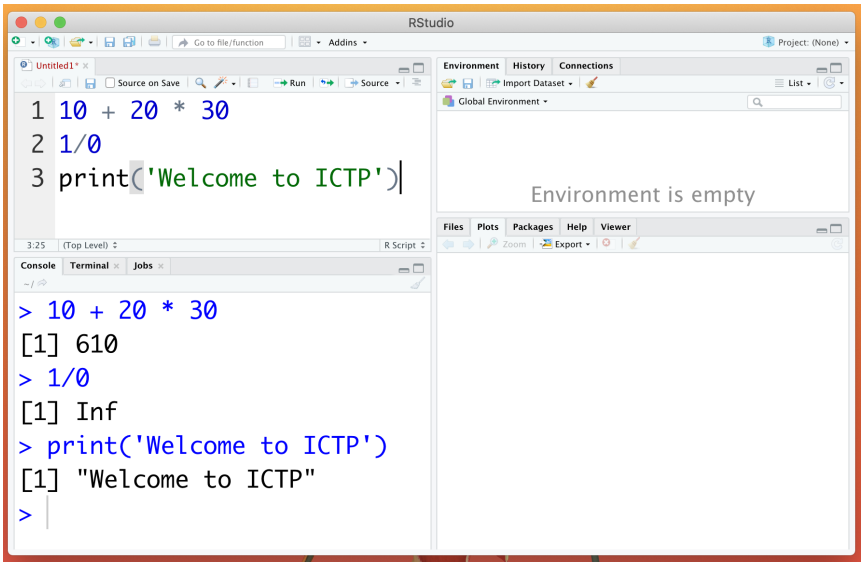

Essendo R un linguaggio di programmazione, è ovviamente possibile iniziare copiando e incollando porzioni di codice trovate in rete, semplicemente 'googlando' o 'chatgipittando' ciò di cui si ha bisogno. Tuttavia, per padroneggiare il linguaggio è necessario dedicare molto tempo alla pratica: i neofiti trovano frustrante cercare il simbolo ~ sulla tastiera, oppure si bloccano quando copiano del codice da un PDF in cui è scritto x – y (con l''en dash' a quattro punti), mentre il software deve leggere x - y (con il segno meno, cioè l''hyphen' a tre punti).

1.3.2 Le interfacce grafiche utente del linguaggio R

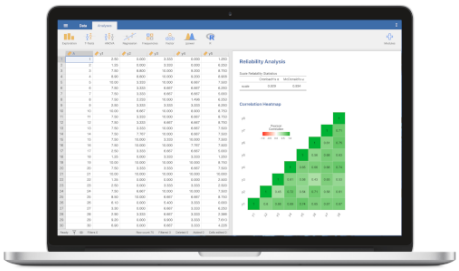

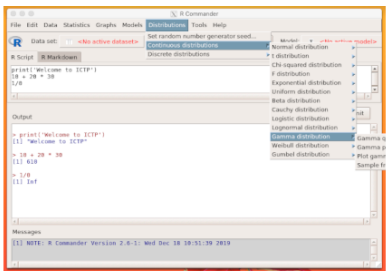

I principianti trovano spesso sufficiente accedere a una selezione dei comandi R più comunemente utilizzati tramite interfacce grafiche utente 'familiari', come R Commander, https://www.rcommander.com/, oppure Jamovi, https://https://www.jamovi.org/. In R Commander è presente un ambiente a menu con una sezione di input, chiamata R Script, creata tramite la procedura File | New Script; e una sezione Output che elenca i comandi inseriti e produce i risultati. In basso, la sezione a sfondo grigio fornisce i Messages, che segnalano eventuali incongruenze. In Jamovi, le capacità di foglio di calcolo per la gestione dei dati grezzi sono integrate con un menu di comandi di analisi tipici di R. Il manuale utente

https://www.jamovi.org/user-manual.html aiuta il principiante ad apprendere le procedure di base.

1.3.3 JASP

Una decina di anni fa, un gruppo di persone appartenenti agli ambiti della ricerca sociale (principalmente dell'Università di Amsterdam, https://cordis.europa.eu/project/id/283876) iniziò a lavorare a una sorta di 'SPSS libero e open source', essendo quest'ultimo una specie di *lingua franca* parlata dagli psicometristi. L'idea era brillante: utilizzare R come motore nascosto (in particolare, sfruttando il pacchetto `BayesFactor`) e racchiuderlo in un'interfaccia 'drag and drop'; il risultato fu la creazione di JASP, che può essere scaricato gratuitamente da https://jasp-stats.org/team/. L'obiettivo originario era promuovere l'approccio bayesiano al test delle ipotesi nelle scienze sociali, riconoscendo che i principali progressi della statistica computazionale avrebbero dovuto avere un impatto positivo sulle metodologie psicometriche tradizionali (o, come sostenevano, addirittura inappropriate). JASP è anch'esso molto ben documentato, e i neofiti possono iniziare consultando https://jasp-stats.org/getting-started/ oppure https://jasp-stats.org/how-to-use-jasp/; sono inoltre molto validi i manuali gratuiti disponibili su https://jasp-stats.org/jasp-materials/. Non a caso, anche la nostra università è amica di JASP (https://jasp-stats.org/world-map/), e tanti dottorandi amano seguire il nostro corso introduttivo, https://sites.google.com/unicz.it/massimoborelli/home.

1.4 Convenzioni tipografiche di questa dispensa

Come vedrete, in questo libro abbiamo adottati alcune convenzioni tipografiche; ad esempio, una risorsa online di particolare importanza viene identificata da un circoletto azzurro:

web Jonathan Ball, Viv Bewick and Liz Cheek. Medical statistics.
https://www.biomedcentral.com/collections/cc-medical

I codici di programmazione saranno trascritti in un box grigio con il bordo azzurro:

codice 1.1 — il primo tentativo. Risale al 1974, e precisamente ad un *gray paper* di Brian Kernighan, pubblicato dall'azienda Bell Laboratories ed intitolato *Programming in C: A Tutorial* il più classico degli output di un programma:

```
/**
```

```
 * Scrive "Hello, World!" nella cella A1 del foglio attivo
 */
function salutaMondo() {
  const foglio = SpreadsheetApp.getActiveSpreadsheet().getActiveSheet();
    foglio.getRange("A1").setValue("Hello, World!");
}
```

■

Di quando in quando, proporremo anche delle

■ **Attività 1.1 — mettiti alla prova.** Prova a fare qualche cosa, magari facendo aiutare dagli amici del tuo gruppo o dall'intelligenza artificiale. ■

e daremo anche qualche definizione importante nel

■ **Vocabolario 1.1 — Parola da ricordare.** In questo modo metteremo l'accento sulla terminologia *must-know* che frequentemente viene usata nel mondo della biostatistica.

o, infine, vi consiglieremo qualche cosa, del tipo:

> **Approfondimento 1.1 — andate in biblioteca.** Perché c'è sempre tanto da imparare sui libri che il nostro Ateneo vi presta gratuitamente.

I Il foglio elettronico intelligente

2 Gli strumenti che useremo 15
2.1 Potenzialità e limiti di Google Fogli 15
2.2 Conosciamo l'editor di Apps Script 16

3 Presentare i dati correttamente 19
3.1 Descrizioni numeriche 19
3.2 Descrizioni grafiche 26

2. Gli strumenti che useremo

Il nostro percorso didattico adotta Google Fogli come una **palestra concettuale**: un ambiente trasparente e collaborativo che ci permetta di mantenere il focus sul dato biologico, riducendo le barriere tecnologiche iniziali. Sebbene lo strumento presenti limiti intrinseci in termini di scalabilitá e riproducibilitá rispetto a software specialistici, tali criticitá vengono mitigate dall'integrazione di **Apps Script**. L'accesso all'Editor di script trasforma il foglio elettronico in un ambiente di sviluppo (IDE) completo, dove la logica algoritmica e il supporto dell'intelligenza artificiale si fondono per aiutare gli studenti ad automatizzare le analisi, rendendoli capaci provare a 'governare' il flusso dei dati oltre le funzioni predefinite.

2.1 Potenzialità e limiti di Google Fogli

La scelta di adottare Google Sheets (o Google Fogli) come strumento didattico non è dettata da una preferenza tecnologica assoluta, ma da un bilancio costi-benefici mirato all'apprendimento. È fondamentale avere una consapevolezza di cosa si possa fare con questo strumento e, soprattutto, di quando sia necessario migrare verso soluzioni più robuste.

Punti di forza e potenzialità

Il foglio elettronico, cosí come inserito nell'*ecosistema cloud* del nostro Ateneo, offre parecchi vantaggi per la didattica laboratoriale:

- **Interfaccia 'Trasparente':** A differenza dei software *point-and-click* (come SPSS, GraphPad Prism, ..) o dei linguaggi di programmazione (come Python, R, ...), Google Sheets mostra il dato e la sua trasformazione nello stesso spazio visivo. Questa vicinanza fisica tra input e output aiuta a comprendere le azioni e le operazioni statistiche.
- **Collaborazione in tempo reale:** La biotecnologia per sua intrinseca natura è una scienza collaborativa. La possibilità per più studenti di lavorare simultaneamente sullo stesso dataset, commentando le analisi e condividendo i risultati, riflette le dinamiche dei laboratori di ricerca anche di natura aziendale.
- **Estensibilità tramite Apps Script:** La presenza, come vedremo meglio fra poco, di un motore JavaScript integrato permette di superare i limiti delle funzioni predefinite, consentendo di creare funzioni personalizzate e di automatizzare il flusso di lavoro (workflow) senza dover installare ambienti di sviluppo complessi.
- **Accessibilità e Cloud:** Non vi sono barriere legate all'hardware o al sistema operativo. Il calcolo avviene sui server, garantendo che ciascuno lavori nelle stesse identiche condizioni tecniche.

Limiti intrinsechi e 'soglie di rischio'

Nonostante le potenzialità, il foglio elettronico presenta dei limiti strutturali che lo rendono inadatto per certi ambiti della ricerca avanzata:

- **Integrità dei dati e Audit Trail:** Google Sheets permette la modifica diretta delle celle: questo espone al rischio di errori accidentali (es. sovrascrittura di una formula) che sono difficili da tracciare rispetto a uno script R o Python, dove il dato originale rimane solitamente immutato (*read-only*).
- **Scalabilità (Big Data):** le biotecnologie moderne (-omiche, sequenziamenti, ...) possono generare istantaneamente milioni di righe di dati. Google Sheets ha limiti fisici sul numero di celle gestibili, oltre i quali le prestazioni degradano fino all'instabilità.
- **Riproducibilità limitata:** la manipolazione manuale dei dati e delle analisi (copia-incolla, ordinamento manuale) rimane la causa principale di errori non riproducibili nella letteratura scientifica prodotta tramite fogli elettronici.
- **Assenza di test statistici avanzati:** molti modelli complessi (modelli lineari generalizzati, modelli misti, analisi di sopravvivenza avanzate, ...) non sono disponibili come funzioni native e richiedererebbero un'implementazione manuale eccessivamente onerosa in Sheets.

In sintesi, ecco perché in questi quattro seminari utilizzeremo Google Sheets come una **palestra concettuale**. Impareremo a 'vedere' la statistica tra le celle, sapendo che le competenze logiche acquisite saranno poi facilmente trasferibili, in futuro, a linguaggi di programmazione più complessi e potenti.

2.2 Conosciamo l'editor di Apps Script

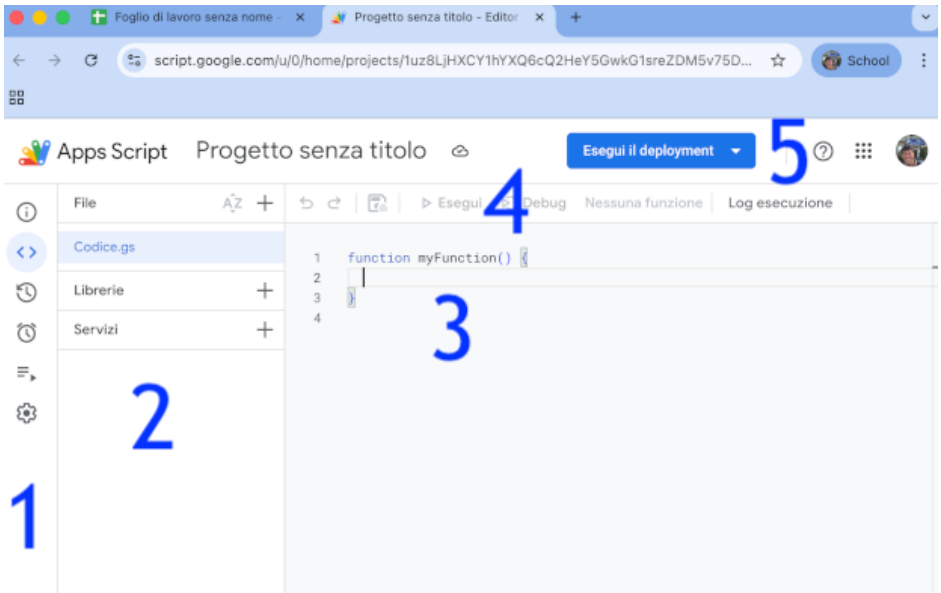

Quando cliccheremo per la prima volta su Apps Script all'interno del menu Estensioni di Google Fogli, il browser aprirà una nuova scheda separata dal foglio di calcolo. Quello che appare non è più una griglia di celle, ma un vero e proprio IDE (Integrated Development Environment) basato su cloud. L'interfaccia è divisa in tre sezioni verticali, pensate per guidare l'utente dalla gestione dei file fino alla scrittura del codice; vi sono poi due sezioni di salvataggio e condivisione.

1. La barra laterale sinistra: il centro di controllo

Sul bordo sinistro si trova una stretta colonna di icone scure. Questa barra permette di navigare tra le diverse 'viste' del progetto:

- **Editor (*Icona del codice*):** è la vista predefinita dove si scrive fisicamente lo script.
- **Attivatori (*Icona della sveglia*):** Una sezione fondamentale dove si può istruire Google a eseguire un codice al verificarsi di un evento, ad esempio ogni lunedì mattina o ogni volta che qualcuno modifica una cella.
- **Esecuzioni (*Icona dell'elenco*):** Qui la studentessa potrà controllare lo storico di tutti i lanci dello script, verificando se sono andati a buon fine o se si sono interrotti con un errore.
- **Impostazioni del progetto (*Icona dell'ingranaggio*):** Per configurare parametri avanzati o collegare lo script a una Google Cloud Platform.

2. Il pannello dei file: l'archivio del progetto

Immediatamente a destra della barra scura, compare un pannello bianco chiamato File: di default, Google crea un file denominato `Codice.gs` e l'estensione `.gs` sta per "Google Script". Qui la studentessa può cliccare sul simbolo "+" per aggiungere nuovi file di script o file HTML (utili se desidera creare finestre pop-up personalizzate all'interno di Fogli).

3. l'editor di testo: il cuore della scrittura del codice

La parte più ampia dello schermo è occupata dall'editor di testo. Al primo accesso, Google inserisce automaticamente uno scheletro di funzione vuota:

```
function myFunction() {

}
```

È qui che avviene la magia. L'editor non è un semplice blocco note: supporta l'autocompletamento (IntelliSense). Se la studentessa scrive "SpreadsheetApp.", l'editor mostrerà un elenco a discesa con tutti i comandi disponibili, spiegando a cosa servono. Se poi, come nel nostro caso, i codici ce li faremo scrivere dall'intelligenza artificiale, la magia sarà perfetta.

4. La barra degli strumenti

: importantissima Sopra l'area del codice si trova una barra orizzontale con alcuni tasti essenziali:

- **Menu delle funzioni:** un piccolo menu a tendina che permette di scegliere quale specifica funzione eseguire (nel caso nel file ce ne siano più di una).
- **Esegui:** il tasto "Play" che avvia il codice.
- **Debug:** rappresentato da un'icona a forma di insetto, serve per analizzare il codice riga per riga alla ricerca di errori logici.
- **Log di esecuzione:** quando lo script viene avviato, nella parte inferiore dell'editor appare un pannello a comparsa che mostra i messaggi di sistema e gli eventuali errori in tempo reale.

5. Il deployment del progetto: non ci riguarda

Con il termine *deployment* in informatica intendiamo l'operazione con cui uno script viene pubblicato come applicazione a se stante, come **Web App** per essere utilizzata da utenti diversi dalla studentessa che ha scritto il codice. Quindi, tramite il pulsante **Esegui il deployment** è possibile definire anche chi possa accedere allo script e quale versione del codice viene resa attiva. Nel nostro corso, gli script verranno utilizzati solo per automatizzare alcune procedure nel foglio di calcolo e non avremo bisogno di alcun deployment.

3. Presentare i dati correttamente

In questo Capitolo impareremo come riassumere dati numerici e non numerici e come presentarli ai lettori, sia in forma tabellare sia in forma grafica. Discuteremo inoltre il modo corretto di farlo, presentando alcuni errori tipici presenti in letteratura.

3.1 Descrizioni numeriche

web Elise Whitley, Jonathan Ball. Statistics review 1: Presenting and summarising data
https://ccforum.biomedcentral.com/articles/10.1186/cc1455

Il primo obiettivo da raggiungere in qualsiasi analisi dei dati è 'comprenderli', descriverli e riassumerli in modo appropriato (senza essere né troppo prolissi, né troppo criptici). Un'analisi di questo tipo può mettere in luce valori 'strani' (outlier), molto elevati o molto bassi rispetto al resto dei dati. Tabelle e grafici sono il modo usuale per riassumere grandi quantità di informazione e la review sopra citata richiama i concetti fondamentali, fornendo esempi di dati qualitativi (non ordinati e ordinati) e quantitativi (discreti e continui). Nella loro review, Elise Whitley e Jonathan Ball ricordano in che modo i diversi tipi di dati possano essere rappresentati, mettendo in evidenza due caratteristiche fondamentali di un dataset quantitativo: la **posizione** dei dati e la loro **variabilità**. Vengono così riviste le comuni misure di posizione (media, mediana e moda) e di variabilità (range, intervallo interquartile, deviazione standard e varianza).

3.1.1 Scheda 1: dati qualitativi e dati quantitativi

Attività didattica 3.1 — Scheda 1. dati qualitativi e dati quantitativi:
https://github.com/umgstat/biotec/blob/main/schede/scheda01.pdf ■

Questa prima scheda ha l'obiettivo di individuare dei criteri operativi per stabilire la 'natura' dei dati statistici e, conseguentemente, di indirizzare l'analisi descrittiva di un dataset. Si tratta di compilare un foglio elettronico Google Sheets, indicando

1. il tuo nome;
2. il tuo cognome;
3. la provincia in cui sei residente (sigla provinciale);
4. quanti chilometri dista, secondo Google Maps, la tua casa di residenza dalla sede di Germaneto nella quale ti trovi ora;

5. quanto sei d'accordo con la seguente affermazione: *Mi ritengo un'utente esperta/o del foglio elettronico.*? Per niente / poco / abbastanza / molto / del tutto.

In statistica, infatti, è fondamentale distinguere tra i diversi tipi di dati, poiché la natura delle variabili osservate condiziona profondamente il tipo di analisi che può essere eseguita e il modo corretto di interpretarne i risultati. Seguendo una classificazione classica, utilizzata ad esempio da Bernie Rosner [32] o da Martin Bland [24], i dati possono essere suddivisi in *qualitativi* e *quantitativi*.

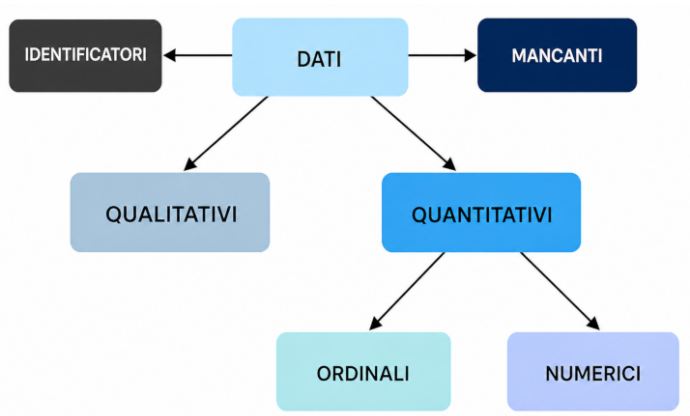

Dati qualitativi. I dati qualitativi (o categoriali) descrivono una qualità, una caratteristica o una categoria alla quale un'osservazione appartiene. Non sono numerici in senso stretto e non ammettono operazioni aritmetiche significative.

- *Dati nominali*: le categorie sono prive di un ordine naturale. Esempi tipici sono il sesso biologico, il gruppo sanguigno, la presenza o assenza di una patologia, oppure la città di residenza.

Dati quantitativi. I dati quantitativi possono descrivere sia grandezze non numeriche, sia grandezze numeriche. Possono esservi dati che non sono numerici in senso stretto e non ammettono operazioni aritmetiche, ma possiedono un loro ordine naturale.

- *Dati ordinali*: le categorie possono essere ordinate secondo un criterio naturale, ma le distanze tra le categorie non sono definite o non sono confrontabili. Esempi comuni sono le scale di giudizio (scarso, sufficiente, buono, ottimo), i livelli di gravità di una malattia o le scale Likert.

Viceversa, abbiamo maggiore versatilità con i dati numerici per i quali le operazioni aritmetiche hanno senso. Essi possono quindi essere rappresentati su una scala numerica e consentono confronti in termini di differenze e, in alcuni casi, di rapporti.

- *Dati discreti, count*: assumono valori numerici interi separati, tipicamente ottenuti tramite conteggio. Esempi sono il numero di figli, il numero di eventi avversi o il numero di accessi ospedalieri.
- *Dati continui*: possono assumere qualunque valore reale all'interno di un intervallo. Altezza, peso, pressione arteriosa e concentrazione di una sostanza nel sangue sono esempi classici.

Dal punto di vista della scala di misura, i dati quantitativi sono generalmente espressi su:

- una *scala a intervalli*, in cui le differenze sono significative ma lo zero è convenzionale (ad esempio la temperatura in gradi Celsius);
- una *scala a rapporti*, in cui esiste uno zero assoluto e sono significativi anche i rapporti tra valori (ad esempio peso, altezza, età).

Come vedremo questa classificazione non è puramente formale: la scelta delle statistiche descrittive e dei grafici (e più in là dei test inferenziali) dipende direttamente dal tipo di dato considerato. Un'analisi corretta inizia quindi sempre da un'attenta identificazione della natura delle variabili osservate.
Vogliamo aggiungere che nei dataset dobbiamo essere pronti a fronteggiare anche due importanti tipologie di dati:

- gli *identificatori*, che spesso anche chiamiamo **chiavi primarie** e che hanno il compito di individuare in maniera univoca il *record* (ossia, la riga) in questione (esempio tipico: il nostro codice fiscale);
- i *dati mancanti*, i *missing data*; sono problematici ma inevitabili, li codifichiamo usualmente con la sigla NA, *not available*, ed esiste tutto un filone di ricerca statistica che si pone come obiettivo quello di 'gestire' i *missing data*.

▪ **Vocabolario 3.1 — dataset completo.** Un dataset si dice **completo** quando non si osserva alcun **dato mancante**, `NA`.

3.1.2 Attenzione: garantire la qualità del dato

web John Ioannidis, et al. How to survive the medical misinformation mess.
https://onlinelibrary.wiley.com/doi/10.1111/eci.12834

Nell'era delle decisioni basate su un'intelligenza artificiale in rapida ascesa, è imperativo essere consapevoli che la letteratura medica può avere un'attendibilità incerta; purtroppo, la maggior parte dei professionisti sanitari non è conscia di questo problema o manca delle competenze necessarie per valutare l'affidabilità e l'utilità delle evidenze mediche. Addirittura, secondo il professor Ioannidis, la maggior parte delle linee guida mediche (sulle quali molti clinici fanno affidamento per orientare le decisioni terapeutiche) non riconosce appieno la scarsa qualità dei dati su cui esse si basano: ci siamo giá resi conto nella sezione precedente di quali siano i limiti del foglio elettronico e di come sia facilmente possibile propagare errori di rappresentazione o di codifica. Se pensiamo che nei laboratori e negli ospedali l'uso del foglio elettronico per la raccolta dati sia una prassi quotidiana, ci rendiamo conto che anche minime incongruenze nel collezionare i dati possono tradursi in errori pericolosi e pervasivi. Pertanto, la prima raccomandazione è ridurre al minimo il rischio di inserimento di dati errati: se il vostro team non ha esperienza nella gestione di database PHP e MySQL, è opportuno almeno imporre l'uso di **Google Moduli** per la raccolta, così da generare automaticamente il foglio elettronico dei dati:

Google Forms Google Sheets

3.1.3 Scheda 2: indici di centralità e di dispersione per i dati qualitativi

Attività didattica 3.2 — Scheda 2. indici di centralità e di dispersione per i dati qualitativi
https://github.com/umgstat/biotec/blob/main/schede/scheda02.pdf ■

La scheda ha l'obiettivo di imparare a calcolare l'indice di centralità (**moda**) e di dispersione (**eterogeneità di Gini**, **entropia di Shannon**) da una tabella di frequenze assolute.

1. importare in un nuovo foglio Google Sheets il dataset ZNF521.txt ;
2. create una tabella nella quale vengano calcolate le **frequenze assolute** e le le **frequenze relative** delle basi azotate A, C, G e T;
3. determinate la **moda** della distribuzione di frequenze;
4. determinate i due indici di eterogeneità maggiormente utilizzati in letteratura, ossia l'(**eterogeneità di Gini** e l'**entropia di Shannon**).

Innanzitutto, prestiamo attenzione al fatto che il dataset ZNF521 è in formato .txt, e pertanto dobbiamo forse fare un po' di fatica nelle operazioni di importazione dei dati (magari, conviene per le prime volte aiutarsi con il Blocco Note o un qualunque altro editor di testo). Prepariamoci al compito, predisponendo uno schema di tabella come quella che vediamo qui sotto nelle colonne C e D:

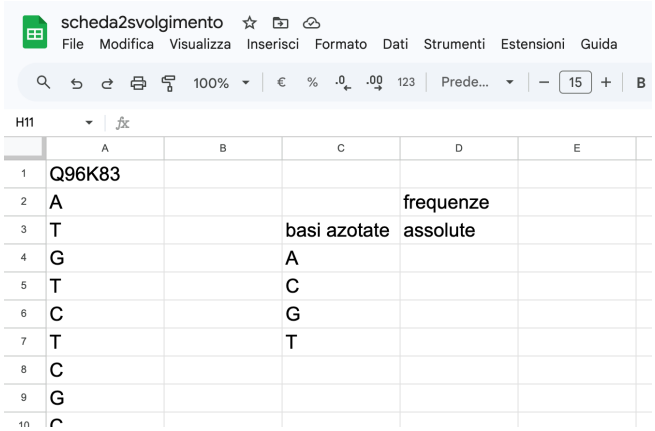

Ora è arrivato il momento magico, quello di provare a chiedere a Gemini di aiutarci a creare il nostro primo Apps Script:

Gemini ci guida passo per passo; vediamo.

Passo 1: Aprire l'editor di script

1. Apri il tuo file Google Sheets.
2. Nel menu in alto, clicca su Estensioni > Apps Script.
3. Si aprirà una nuova scheda del browser con un editor di codice. Vedrai una funzione predefinita chiamata `function myFunction() ...`. Puoi cancellare tutto il contenuto e incollarci il codice che trovi qui sotto.

Passo 2: Incollare il codice Copia e incolla questo script nell'editor:

codice 3.1 — JavaScript.
```
function contaLettereSpecifiche() {
  // 1. Ottieni il foglio di lavoro attivo chiamato "scheda2svolgimento"
  var sheet = SpreadsheetApp.getActiveSpreadsheet().getSheetByName(
  "scheda2svolgimento");

  if (!sheet) {
    SpreadsheetApp.getUi().alert("Errore: Il foglio 'scheda2svolgimento'
    non e' stato trovato. Verifica il nome della scheda.");
    return;
  }

  // 2. Leggi i dati dall'intervallo A2:A3937
  var range = sheet.getRange("A2:A3937");
  var values = range.getValues(); // Ottiene un array di valori

  // 3. Inizializza i contatori
  var counts = { 'A': 0, 'C': 0, 'G': 0, 'T': 0 };

  // 4. Cicla tra le celle e conta le lettere
  for (var i = 0; i < values.length; i++) {
    var cellValue = String(values[i][0]).toUpperCase(); // Trasformiamo in
    maiuscolo per sicurezza

    // Controlliamo ogni carattere della stringa nella cella
    for (var char of cellValue) {
      if (counts.hasOwnProperty(char)) {
        counts[char]++;
      }
    }
  }

  // 5. Scrivi i risultati nelle celle D4, D5, D6, D7
  sheet.getRange("D4").setValue(counts['A']);
  sheet.getRange("D5").setValue(counts['C']);
  sheet.getRange("D6").setValue(counts['G']);
  sheet.getRange("D7").setValue(counts['T']);

  // 6. Imposta lo sfondo azzurro (codice esadecimale #ADD8E6)
  sheet.getRange("D4:D7").setBackground("#ADD8E6");

  // Messaggio di conferma opzionale
```

```
  SpreadsheetApp.getUi().alert("Operazione completata! Lettere contate e
  celle aggiornate.");
}
```
■

Passo 3: Salvare ed eseguire

1. Clicca sull'icona del **dischetto** (Salva) nella barra degli strumenti in alto. Dai un nome al progetto (es. "ContatoreLettere").
2. Assicurati che nel menu a tendina accanto al pulsante "Esegui" sia selezionata la funzione `contaLettereSpecifiche`.
3. Clicca sul pulsante **Esegui**.

Passo 4: Autorizzazioni (Importante) Poiché è la prima volta che esegui uno script su questo foglio, Google ti chiederà il permesso:

1. Ti apparirà una finestra "Autorizzazione richiesta". Clicca su **Esamina autorizzazioni**.
2. Scegli il tuo account Google.
3. Probabilmente vedrai un avviso: "Google non ha verificato questa app" (è normale, è uno script creato da te). Clicca su **Avanzate** (in basso a sinistra) e poi su **Vai a ContatoreLettere (non sicuro)**.
4. Clicca su **Consenti**.

Lo script verrà eseguito e vedrai i numeri apparire nelle celle **D4:D7** con lo sfondo azzurro!

Con una certa soddisfazione, noteremo che le quattro celle sono diventate azzurre e contengono proprio le frequenze che desideravamo ottenere:

	C	D
		frequenze
	basi azotate	assolute
	A	1136
	C	1012
	G	903
	T	885

Molto bene! Ora diventa tutto quasi banale: basta modificare il prompt e chiedere (con gentilezza) a Gemini di aiutarci a calcolare anche le **frequenze relative**, ossia, le percentuali. Fatto questo, possiamo chiedere un aiuto a Wikipedia per scoprire le definizioni dell'**indice di eterogeneità di Gini**, I e dell'**entropia di Shannon**, S, adattandole nel nostro caso:

$$I = 1 - \left(f_A^2 + f_C^2 + f_G^2 + f_T^2\right)$$

$$S = -\left(f_A \cdot log_2(f_A) + f_C \cdot log_2(f_C) + f_G \cdot log_2(f_G) + f_T \cdot log_2(f_T)\right)$$

dove, banalmente, $f_A = 0.29, f_C = 0.26, f_G = 0.23, f_T = 0.22$ sono le quattro frequenze relative che avevamo appena calcolato.

Approfondimento 3.1 — disordine ed informazione. Possiamo provare a farci un'idea basilare del perché l'entropia di Shannon rappresenti una misura del disordine. Consideriamo, come faceva Claude Shannon, i bit (0 ed 1), e supponiamo che ci sia una percentuale x di zeri, ed $1-x$ di uni. In tal caso la funzione S diventa:

$$S = -\left(x \cdot log_2(x) + (1-x) \cdot log_2(1-x)\right)$$

e noi possiamo disegnarla con una calcolatrice grafica (ad esempio Geogebra, o Desmos).

Osserveremo che se $x = 1 - x = 0.50$ abbiamo $S = 1$, ossia il massimo disordine, dunque massima imprevedibilità e minima informazione. Viceversa se $x \approx 0$ oppure $x \approx 1$, allora $S \approx 0$, pochissimo disordine, dunque pochissima imprevedibilità, quindi molta prevedibilità e molta informazione.

3.1.4 Scheda 3: indici di centralità e di dispersione per i dati quantitativi

Attività didattica 3.3 — Scheda 3. indici di centralità e di dispersione per i dati qualitativi
https://github.com/umgstat/biotec/blob/main/schede/scheda03.pdf ■

La scheda ha l'obiettivo di imparare a calcolare gli indici di centralità (**media** e **mediana**) e di dispersione (**deviazione standard** e **quartili**) da una variabile, numerica oppure ordinale.

1. importare in un nuovo foglio Google Sheets il dataset her2.ods ;
2. create delle tabelle nella quali vengano calcolati gli indici di centralità e di dispersione della etadiagnosi e immunoistochimica dei pazienti;

Adesso, prestiamo invece attenzione al fatto che il dataset her2 è in formato .ods; dunque dobbiamo fare un po' meno fatica di prima per importarlo in Google Sheets. Se vi viene comodo, potete continuare a usare Gemini ed Apps Script; oppure, potete digitare testualmente le funzioni MEDIA(), DEV.ST(), MEDIANA() oppure QUARTILI(), indicando l'intervallo dei dati come argomento delle funzioni (badando che la funzione che calcola i quartili necessita anche di conoscere di che quartile abbiamo bisogno)

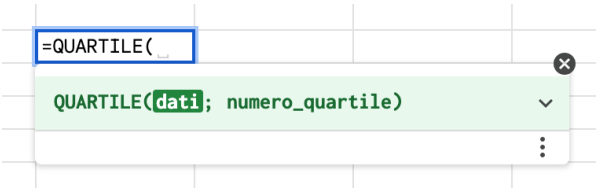

Vale anche la pena osservare che invece di dividere i dati in quattro parti, avremmo potuto farlo in tre, o in dieci, o in cento parti uguali. Ecco dunque la definizione da ricordare:

■ **Vocabolario 3.2 — Quantili.** Quartili, terzili, decili e percentili sono esempi di **quantili**.

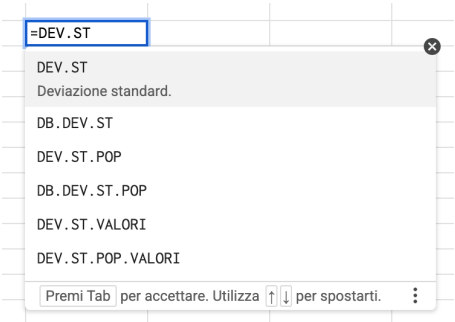

Vogliamo concludere questa scheda di attività precisando quale sia la funzione 'che fa al caso nostro' per calcolare la deviazione standard, visto che il foglio elettronico ne propone almeno una dozzina di diverse. Teniamo presente che noi non siamo l'Istat che conosce tutti i dati della **popolazione**, ma tutti i nostri esperimenti si svolgono su (anche piuttosto piccoli) **campioni**, ossia un sottoinsieme di elementi tratti da un più ampio insieme detto, appunto, popolazione. Osserviamo attentamente i denominatori delle formule che definiscono le due diverse deviazioni standard:

$$\text{popolazione: } \sqrt{\frac{\sum_i^n (x_i - m)^2}{n}}, \text{ campione: } \sqrt{\frac{\sum_i^n (x_i - m)^2}{n-1}}$$

I libri di statistica matematica (ad esempio [31]) spiegano perfettamente perché questo sia opportuno, richiamando i concetti di 'stimatore statistico corretto' e 'stimatore statistico coerente'. Per capirlo facilmente vi invento una storiella. Supponiamo che Massimino Borellino al liceo abbia ricevuto rispettivamente il voto x ed il voto y nel primo e nel secondo compito di latino. Supponiamo che la mamma di Massimino scopra che il voto medio dei due compiti è 6. Riuscirebbe la mamma di Massimino a dedurre il voto x ed il voto y? No, perché disporrebbe di una sola informazione rispetto ai due voti ignoti. Viceversa, supponiamo che la mamma di Massimino scopra dal registro elettronico che il voto medio dei due compiti è 6 e che la deviazione standard è 1.41. Riuscirebbe la mamma a scoprire i voti x ed il voto y? Eh sì, eh:

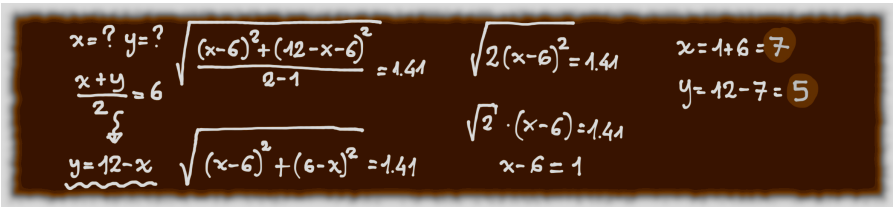

Dunque, ricapitolando. Se conosciamo la media abbiamo 1 informazione sull'andamento scolastico di Massimino; quindi per conoscere gli $n = 2$ voti ce ne manca ancora $(n-1) = 2-1 = 1$ di informazione. Ecco l'intuizione: quel denominatore $(n-1)$ rappresenta quante informazioni ci mancano per conoscere compiutamente tutti i valori della variabile in esame, partendo dalla loro media.

3.2 Descrizioni grafiche

3.2.1 Scheda 4: Rappresentare graficamente i dati

web Yan Holtz. The R Graph Gallery.
https://www.r-graph-gallery.com/

1. visitare il sito https://r-graph-gallery.com/
2. esplorare ad uno ad uno i grafici che vengono proposti
3. riutilizzare il foglio Google Sheets con il dataset her2.ods, concentrandosi sulle variabili etadiagnosi, immunoistochimica ed ER;
4. prepararsi alla discussione in aula circa l'abbinamento dei diversi grafici ai diversi tipi di dato numerico
5. realizzare un **boxplot** di etadiagnosi
6. realizzare un **istogramma** di etadiagnosi

Dopo aver esplorato le le potenti capacità grafiche di R, diamo un breve sguardo a quali di queste possibilità vengano implementate nel foglio elttronico, tenendo presente che diversi tipi di variabili (nominali, ordinali, scalari) richiedono rappresentazioni grafiche differenti:

- Diagrammi a torta, *pie chart*: adatti alle variabili di tipo qualitativo, espresse come frequenze assolute o relative
- Diagrammi a barre, *barplot*: adatti alle variabili di tipo quantitativo ordinale
- Istogrammi: adatti alle variabili di tipo quantitativo numerico

Se vogliamo essere super precisi, dedichiamo qualche minuto a chiarire la differenza tra il diagramma a barre ed all'istogramma: entrambi rientrano nella categoria 'Distribution plots',

tuttavia, parlando di istogrammi, in essi l'altezza di ciascun blocco verticale non rappresenta sempre il valore della variabile di interesse (a meno che la larghezza del blocco sia unitaria), come accade invece per le barre di un bar chart. Inoltre, in un istogramma, la scala orizzontale è continua e non discreta, come nei bar chart. Infine, a differenza della larghezza delle barre, la larghezza dei blocchi di un istogramma *ha un significato*.

Concludiamo questa sezione ricordando anche il grafico denominato **box-plot**, nel quale le distanze tra le diverse parti del box indicano il grado di dispersione dei dati e la loro asimmetria dei dati; i baffi inoltre individuano le **code della distribuzione** .

Attività didattica 3.4 Cercate in rete cosa rappresentano i punti isolati che compaiono in certi boxplot e che vengono detti **outliers**, così come definiti da Tukey utilizzando l'intervallo interquartile. ■

3.2.2 Ricordiamoci sempre di rispettare i nostri interlocuori

web Alla Katsnelson. Colour me better: fixing figures for colour blindness
https://www.nature.com/articles/d41586-021-02696-z

Non dobbiamo dimenticare che, a livello mondiale, la deficienza nella visione dei colori nei maschi è stimata essere intorno al 5–10% della popolazione: questo è un invito a preferire, quando possibile, l'adozione della cosiddetta palette di colori *viridis* nei grafici e a valorizzare le diverse informazioni anche tramite codifiche grafiche differenti (linee continue, tratteggiate, puntinate, . . .).

Attività didattica 3.5 Cercate in rete cosa significa utilizzare la *palette* Viridis. ■

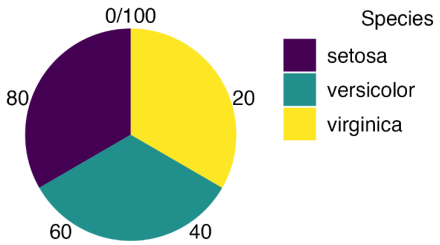

Figura 3.1: Un diagramma a torta con palette Viridis